

Análisis de Copias Certificadas de RENIEC mediante MapReduce en Hadoop

Evaluación de Trámites Documentales (2021-2026)

Luna Jaramillo, Christian Giovanni
Llanos Rosadio, José Ismael
Sánchez Vega, Andre Alvaro

Universidad Nacional de Ingeniería
Facultad de Ciencias
Curso: Análisis en Macrodatos (CC531A)

15 de Abril de 2026

Descripción

Implementación de ocho consultas MapReduce sobre el dataset público de RENIEC para analizar la emisión de copias certificadas por domicilio y género.

- **Dataset:** Registros mensuales (Sept. 2021 - Feb. 2026).
- **Alcance:** Desde agregaciones simples hasta modelos predictivos de regresión lineal.
- **Tecnología:** Ecosistema Hadoop (HDFS/MapReduce).

- El análisis de grandes volúmenes de datos gubernamentales permite identificar tendencias demográficas críticas.
- **Problema:** Procesar registros masivos distribuidos en 51 archivos mensuales de la Plataforma Nacional de Datos Abiertos (PNDA).
- **Solución:** Uso de procesamiento paralelo y distribuido bajo el paradigma **MapReduce**.

Objetivo General

Extraer conocimiento estadístico y predictivo de los trámites de RENIEC mediante programación distribuida.

- Implementar consultas multivariantes y filtros temporales.
- Calcular métricas de dispersión (Mediana y Desviación Estándar).
- Desarrollar modelos de clasificación y predicción mediante el encadenamiento de *Jobs* (Job Chaining).

Fases del Proyecto:

- ➊ **Preprocesamiento (Python/Polars):** Unión de CSVs y limpieza de caracteres BOM.
- ➋ **Almacenamiento:** Carga de Registros.csv en HDFS.
- ➌ **Procesamiento:** Desarrollo de Mappers/Reducers en Java 8.

Entorno:

- Apache Hadoop 2.8.0.
- API *mapred* (Modelos Writable).

Consulta 1: Agregaciones con Múltiples Campos

- **1.1 Total por Depto/Prov/Género:** Clave compuesta [4]-[5]-[3].
- **1.2 Nacimientos por Año/Provincia:** Filtro Tipo == Nacimiento.

Resultados Reales

Clave Agrupada	Cantidad
LIMA - LIMA - FEMENINO	245,893
LIMA - LIMA - MASCULINO	210,467
2021 - ABANCAY (Nacimientos)	392
2022 - LIMA (Nacimientos)	87,503

Consulta 1.4 y 1.5: Valores Extremos por Mes

Se utilizó un **HashMap** en la fase de reducción para comparar todas las provincias de un mismo periodo.

- **C1.4 (Máximos):** En Enero 2023, la provincia con más trámites fue **LIMA** con 125,430.
- **C1.5 (Mínimos):** Identificación de provincias con mínima actividad (ej. Purús).

Consulta 2: Promedio, Mediana y Desviación

Análisis de Dispersión Mensual:

Año - Mes	Promedio	Mediana	Desv. Std
2021 - ABRIL	74.63	4.00	756.78
2026 - FEBRERO	42.10	2.00	489.23

Interpretación

La mediana drásticamente menor al promedio confirma un **sesgo positivo extremo**. Pocas entidades (como Lima) concentran la gran mayoría de trámites nacionales.

Consulta 3 y 4: Filtros de Texto y Fecha

Consulta 3: Búsqueda de "LIMA"

```
if(rowText.toLowerCase().contains("lima")) {  
    output.collect(new Text("Resultado: "), value);  
}
```

Resultado: 3,089 registros encontrados.

Consulta 4: Rango Abr 2023 - Nov 2025

- Lógica: $ID = (anio * 100) + mes \in [202304, 202511]$.
- *Resultado: 41,870 registros.*

Consulta 6: Desviación Provincial (2 Jobs)

- 1 **Job 1:** Calcula el promedio nacional del año en curso.
- 2 **Job 2:** Calcula la desviación individual: $V_{prov} - \bar{x}_{anual}$.

Ejemplo de Salida (2023)

- **LIMA:** Cant 26,350 — Diferencia: **+26,301.80**
- **HUARAZ:** Cant 15 — Diferencia: **-33.20**

Consulta 7: Modelo de Clasificación Demográfica

Compara nacimientos y defunciones mensuales contra sus promedios históricos.

- **Perfil ALTA NATALIDAD:** Nacimientos $>$ Promedio.

Caso 2021

2021-MARZO: Nac 58,089 (Prom: 37,623) | PERFIL:
ALTA_NATALIDAD

Este Job carga los promedios calculados en el Job anterior desde HDFS mediante el método `configure()`.

Consulta 8: Predicción 2026 (3 Jobs)

Metodología: Regresión Lineal por Mínimos Cuadrados.

$$\hat{y} = mx + b$$

Resultados de Predicción (Diciembre 2026)

Métrica	Valor Predicho
Nacimientos Mensuales	54,063
Defunciones Mensuales	1,811

Discrepancia de Datos

El mes de "Septiembre" no fue predicho debido a que el dataset usa el término "Setiembre", causando un error de mapeo en el modelo.

Conclusiones

- **Eficiencia:** Hadoop MapReduce procesó registros masivos distribuidos, reduciendo tiempos de análisis estadístico.
- **Análisis Geográfico:** Los resultados demuestran una centralización extrema en Lima Metropolitana.
- **Modelado:** El encadenamiento de trabajos (Jobs) permitió pasar de conteos simples a modelos predictivos complejos.
- **Tendencia:** Se proyecta una alta natalidad sostenida para el cierre del año 2026.

¡Gracias por su atención!

¿Preguntas?