

Escuela de Ciencia de la Computación

Examen Parcial


CC531 A Análisis en Macrodatos 2026-1

Parte 1 [6 pts]:

Resolver en el laboratorio de clase de forma presencial 6 preguntas de teoría de forma individual, en hoja y con lapicero.

Parte 2 [14 pts]:

Se pide configurar y programar un Clúster de Hadoop e instalar Hadoop multimodo 1 maestro y 2 o más esclavos, en máquinas virtuales mínima de Ubuntu siguiendo el tutorial y demostración presentado en clase, Desarrollar un informe, Una presentación y Exponer sobre una base de datos para su Análisis según las siguientes restricciones:



Implementar:

- Implementar un Clúster de Hadoop e instalar Hadoop multimodo **1 maestro y 2 o más esclavos**, en máquinas virtuales de Ubuntu o Windows usando virtual box u otro virtualizador a su criterio.
- Elaborar un informe en el cual:
 - Adicional a las secciones de siempre, crear una sección inicial de implementación donde se describirá a grandes rasgos los pasos seguidos con capturas de la configuración.
 - Adjuntando las capturas de pantalla de cada paso de configuración y la pantalla final donde aparecen los nodos conectados.
- Implementar o usar su VM de un nodo para que comparen rendimientos en los trabajos realizados.
- Buscar un Dataset de la Plataforma Nacional de Datos Abiertos (PNDA) que no haya sido expuesto en las PC por ningún grupo (base de datos) y que sea de las **categorías EDUCACIÓN O SALUD**. **Revisar en el cuadro de temas los ya utilizados por los otros grupos, no se admitirá datasets repetidos ni con muestras de datos en diferentes periodos.**
- Tanto en el informe como en la presentación:
 - Referenciar la base de datos usada.
 - Referencias investigaciones anteriores realizadas a la base datos.
 - Indicar la fuente de dataset y la fecha de publicación, se tomará en cuenta las bases de datos más recientes.
 - Referenciar artículos que usaron su dataset si lo hubiera hecho.

- Implementar Consultas de complejidad en Hadoop
 - Hacer 3 consultas con decimales que implique al menos un Mapreduce doble. Cada consulta por separado debe tener el Mapreduce doble como se vio en clase.
 - Implementar 1 consulta con campos decimales o cadenas de 1 modelo de machine de clasificación (arboles de decisión, Random Forest, Support Vector Machine , KNN o Native Bayes) utilizando Hadoop Mapreduce.
 - Implementar 1 consulta con campos decimales o cadenas de 1 modelo de redes neuronales usando el concepto clásico de gradiente descendiente en Hadoop Mapreduce.
- Correr su código en el clúster implementado y en la versión de un solo nodo (El que implementaron para la PC1).
- Implementar una tabla de comparación que mida: Los tiempos de ejecución, el speedup, uso promedio de CPU y memoria en paralelo y en un solo nodo. La tabla y explicación de la razón de las salidas debe estar en el informe y en la presentación.
- Adicionar en el informe la imagen del monitor de recursos de la ejecución en paralelo (ejemplo htop) de memoria, de cada procesador, y tiempos de ejecución de cada caso de los nodos en la red, para observar el paralelismo de los procesos.
- Para el caso de las preguntas de Machine learning elaborar una tabla donde se compare las métricas de perdida, accuracy y otras medidas propias que elijan para cada modelo en los casos paralelos y 1 solo nodo, para compararlos.
- En el informe y presentación para mantener la organización por cada consulta se debe mencionar:
 - Especificar el tipo de pregunta o grupo de pregunta.
 - Mencionar la consulta en el Dataset a la cual responde. Ejem: “Cual es el promedio de marcas usadas...”
 - Explicar la solución y resultados.
- Agregar al informe y presentación los inputs y outputs que pudiera tener sus consultas.
- Con los resultados obtenidos de las consultas implementar gráficos usando Power BI y adjuntarlos a su informe y presentación. Mínimo 4 gráficos de los tipos vistos en clase.
- Durante la exposición se debe mostrar la ejecución del clúster implementado distribuido y el de un solo nodo.

Donde se tenga en cuenta de:

- Tomar como base las prácticas de clase y las versiones usadas en ella de ser posible.
- Explorar y analizar la información.
- Interpretación de los resultados.
- Para la segunda parte serán en grupos de **3 personas como máximo** , todos los miembros deben estar presentes al momento de la exposición sino **no se considerará su evaluación por más que coloquen como miembro en su presentación.**

Comprimir todos los archivos en un archivo:

- Utilizar las plantillas mostradas en la PC1 para presentación e informe.
- Adjuntar los códigos con extensión java y también jar y los archivos de Power BI así como las salidas de hadoop.
- Adjuntar el Informe con la plantilla.

- Adjuntar la presentación de su proyecto
- Entregar todo en un zip a través del aula virtual UNI hasta la fecha límite. (cada integrante del grupo debe subirlo por separado)