

Análisis de Infraestructura Aeroportuaria del Perú 2022–2024 mediante Herramientas de Macrodatos

Estudiantes:

Luna Jaramillo, Christian Giovanni
Universidad Nacional de Ingeniería, Facultad de Ciencias,
e-mail: christian.luna.j@uni.pe

Llanos Rosadio, José Ismael
Universidad Nacional de Ingeniería, Facultad de Ciencias,
e-mail: jose.llanos.r@uni.pe

Sánchez Vega, Andre Alvaro
Universidad Nacional de Ingeniería, Facultad de Ciencias,
e-mail: andre.sanchez.v@uni.pe

Curso:

CC531A – Análisis en Macrodatos
PC2

Abstract

El presente informe desarrolla un análisis exhaustivo del conjunto de datos de infraestructura aeroportuaria del Perú correspondiente al período 2022–2024, obtenido de la Plataforma Nacional de Datos Abiertos (PNDA). Se aplican procesos de Extracción, Transformación y Carga (ETL) sobre los datos originales en formato XLSX, seguidos de un análisis exploratorio mediante Python (Pandas, NumPy, Matplotlib, Seaborn) y visualizaciones interactivas en Power BI. El análisis comprende siete tipos de consultas: agrupaciones con gráficos de barras, creación de columnas derivadas, matriz de correlación, gráficos combinados, gráficos de líneas, tendencias acumulativas y gráficos de torta con filtros condicionales. Los resultados revelan patrones de concentración geográfica en la región Selva, la dominancia de CORPAC S.A. como administrador público principal, y la estabilidad relativa del inventario en el período analizado. Asimismo, se identificaron inconsistencias en la clasificación geográfica de algunas instalaciones que ameritan revisión en el dataset oficial.

Palabras clave: infraestructura aeroportuaria, ETL, Pandas, Power BI, macrodatos, Perú, aeropuertos.

Contents

1	Introducción	2
2	Marco Teórico	3
2.1	Macrodatos y Datos Abiertos Gubernamentales	3
2.2	Proceso ETL	3
2.3	Herramientas de Análisis en Python	3
2.4	Power BI como Herramienta de Business Intelligence	4
2.5	Infraestructura Aeroportuaria del Perú	4

3	Metodología	4
3.1	Adquisición y Descripción del Dataset	4
3.2	Proceso ETL Implementado	4
3.2.1	Extracción	4
3.2.2	Transformación	5
3.2.3	Carga	5
3.3	Análisis en Python	5
3.4	Dashboards en Power BI	5
4	Resultados y Discusión	5
4.1	Consulta 1: Gráficos de Barras Agrupadas	5
4.1.1	Consulta 1.1 – Infraestructura por Departamento, Tipo y Estado	5
4.1.2	Consulta 1.2 – Infraestructura por Administrador, Jerarquía y Titularidad	6
4.2	Consulta 2: Creación de Nuevas Columnas	7
4.2.1	Columna MACROREGION	7
4.2.2	Columna SITUACION_LEGAL	8
4.2.3	Columna ANIO_CORTE	8
4.3	Consulta 3: Matriz de Correlación	8
4.4	Consulta 4: Gráficos Combinados de Barras Agrupadas	9
4.4.1	Gráfico 4.1 – Infraestructura por Macroregión, Tipo y Estado	9
4.4.2	Gráfico 4.2 – Top 5 Administradores por Jerarquía y Situación Legal	9
4.5	Consulta 5: Gráficos de Líneas con Agrupación	10
4.5.1	Gráfico 5.1 – Evolución por Año, Macroregión y Tipo	10
4.5.2	Gráfico 5.2 – Tendencia por Año, Situación Legal y Jerarquía	11
4.6	Consulta 6: Gráficos de Tendencia Acumulativa	11
4.6.1	Gráfico 6.1 – Acumulado por Macroregión	11
4.6.2	Gráfico 6.2 – Acumulado por Situación Legal	12
4.6.3	Gráfico 6.3 – Acumulado por Tipo de Aeródromo	13
4.7	Consulta 7: Gráficos de Torta con Filtros Condicionales	13
4.7.1	Gráfico 7.1 – Proporción de Tipos en la Región SELVA	13
4.7.2	Gráfico 7.2 – Distribución de Jerarquía en la Región COSTA	14
4.8	Resultados en Power BI	15
4.8.1	Páginas C.1.1 y C.1.2 – Gráficos de Columnas Apiladas	15
4.8.2	Páginas C.2.1 y C.2.2 – Gráficos de Líneas	15
4.8.3	Página C.3 – Diagramas de Dispersión	16
4.8.4	Página C.4 – Mapa de Burbujas	17
4.8.5	Página C.5 – Gráfico de Torta	17
4.9	Resumen de Hallazgos	17
5	Conclusiones	18
6	Anexo: Código Python	18
7	Anexo: Documentación del Dataset	20
	Bibliografía	22

1 Introducción

La infraestructura de transporte aéreo constituye un elemento crítico para la conectividad interna y el desarrollo económico del Perú, país caracterizado por su compleja geografía que dificulta el acceso terrestre a numerosas regiones, especialmente en la Amazonía y la Sierra. Frente a esta realidad, la red de aeropuertos, aeródromos y helicópteros representa el principal enlace entre las comunidades rurales remotas, las operaciones extractivas y los centros urbanos [9].

En el marco de la asignatura CC531-26-1 *Análisis en Macrodatos*, el presente trabajo aplica un conjunto de herramientas y técnicas propias de la ciencia de datos sobre el conjunto de datos oficial de *Infraestructura*

Aeroportuaria – Aeródromos 2022–2024, publicado por el Ministerio de Transportes y Comunicaciones del Perú a través de la Plataforma Nacional de Datos Abiertos (PNDA). El dataset comprende información georeferenciada sobre aeropuertos, aeródromos y helicópteros a nivel nacional, con atributos de administración, jerarquía, estado operativo y situación legal.

Los objetivos específicos del trabajo son:

- Realizar el proceso ETL completo sobre el dataset original en formato XLSX, generando archivos CSV limpios y enriquecidos.
- Generar múltiples visualizaciones analíticas mediante Python, incluyendo gráficos de barras agrupadas, matrices de correlación, gráficos de líneas, tendencias acumulativas y tortas con filtros condicionales.
- Construir dashboards interactivos en Power BI con columnas apiladas, líneas temporales, diagramas de dispersión, mapas geográficos y gráficos de torta.
- Interpretar los resultados obtenidos y extraer conclusiones sobre la distribución y evolución de la infraestructura aeroportuaria peruana en el período 2022–2024.

2 Marco Teórico

2.1 Macrodatos y Datos Abiertos Gubernamentales

El término *macrodatos* (Big Data) hace referencia a conjuntos de datos de gran volumen, variedad y velocidad cuyo procesamiento supera la capacidad de las herramientas tradicionales. En el contexto de los datos públicos abiertos, las técnicas de análisis de macrodatos permiten extraer conocimiento útil para la gestión pública, la investigación académica y la toma de decisiones basada en evidencia [7]. La Plataforma Nacional de Datos Abiertos (PNDA) del Perú representa un repositorio oficial de datasets gubernamentales disponibles para la ciudadanía y la academia [10].

2.2 Proceso ETL

El proceso **ETL** (Extract, Transform, Load) es una metodología estándar en ingeniería de datos que comprende tres fases principales [6]:

- **Extracción (Extract):** obtención de datos desde la fuente original. En este trabajo, la fuente es un archivo XLSX proveniente de la PNDA.
- **Transformación (Transform):** limpieza, normalización Unicode, manejo de valores nulos, corrección de codificación, conversión de tipos y creación de variables derivadas que enriquecen el dataset.
- **Carga (Load):** almacenamiento de los datos transformados en un formato optimizado para el análisis posterior. En este caso se generan archivos CSV con codificación UTF-8-SIG.

La correcta implementación del proceso ETL es fundamental para garantizar la calidad y consistencia de los datos antes del análisis. Problemas como caracteres mal codificados (mojibake), valores nulos no tratados o tipos de datos inconsistentes pueden sesgar los resultados si no se abordan en esta etapa [11].

2.3 Herramientas de Análisis en Python

Para el análisis de datos se emplearon las siguientes bibliotecas del ecosistema científico de Python:

- **Pandas** [8]: biblioteca de análisis y manipulación de datos que provee estructuras de datos flexibles (DataFrames y Series) con operaciones optimizadas de agrupación (**groupby**), filtrado, combinación y transformación.
- **NumPy** [4]: biblioteca para computación numérica eficiente, utilizada para operaciones vectoriales, manejo de arrays multidimensionales y cálculos estadísticos.
- **Matplotlib** [5]: biblioteca de visualización estática que permite crear gráficos de alta calidad en múltiples formatos (PNG, SVG, PDF). Provee control fino sobre todos los elementos gráficos.
- **Seaborn** [12]: biblioteca de visualización estadística construida sobre Matplotlib, que facilita la creación de gráficos como mapas de calor de correlación, gráficos de violín y diagramas de distribución con menor código.

2.4 Power BI como Herramienta de Business Intelligence

Microsoft Power BI es una plataforma de inteligencia empresarial que permite conectar múltiples fuentes de datos, transformarlos mediante Power Query (basado en el lenguaje M) y construir dashboards interactivos con una amplia variedad de visualizaciones [3]. Su capacidad de georreferenciación mediante mapas de burbujas y la interactividad entre gráficos lo hacen especialmente adecuado para el análisis de infraestructura nacional con componente espacial.

2.5 Infraestructura Aeroportuaria del Perú

La red aeroportuaria del Perú está conformada por aeropuertos internacionales, aeropuertos nacionales, aeródromos y helicópteros distribuidos en los 25 departamentos del país. La Corporación Peruana de Aeropuertos y Aviación Comercial (CORPAC S.A.) es el principal operador público, responsable de la administración de los aeropuertos no concesionados [2]. Los aeropuertos de mayor tráfico han sido entregados en concesión a operadores privados: Lima Airport Partners (Jorge Chávez), Aeropuertos del Perú (norte y centro-orienté) y Aeropuertos Andinos del Perú (sur andino).

La clasificación por tipo comprende: *Aeropuerto* (pista pavimentada, capacidad para avión de mayor porte), *Aeródromo* (instalación menor, pista no necesariamente pavimentada) y *Helicóptero* (plataforma de aterrizaje exclusiva para helicópteros, usualmente en zonas extractivas).

3 Metodología

3.1 Adquisición y Descripción del Dataset

El dataset fue obtenido de la Plataforma Nacional de Datos Abiertos (PNDA) del Perú, categoría de Transporte. El archivo original (`xlsx_file.xlsx`) contiene 21 columnas y registros correspondientes a los años de corte 2022, 2023 y 2024 (fechas: 20221231, 20231231, 20241231). El dataset cumple los requisitos del trabajo al pertenecer a la categoría de transporte e incluir coordenadas geográficas (latitud y longitud) para georreferenciación.

La Tabla 1 describe los campos principales del dataset original.

Table 1: Campos principales del dataset de infraestructura aeroportuaria

Campo	Tipo	Descripción
ID_AERODROMO	Entero	Identificador único del aeródromo en el registro
ID_DEPARTAMENTO	Entero	Código UBIGEO nivel departamento
ID_PROVINCIA	Entero	Código UBIGEO nivel provincia
ID_DISTRITO	Entero	Código UBIGEO nivel distrito
DEPARTAMENTO	Texto	Nombre del departamento de ubicación
PROVINCIA	Texto	Nombre de la provincia de ubicación
DISTRITO	Texto	Nombre del distrito de ubicación
NOMBRE	Texto	Nombre oficial del aeródromo
TIPO_AERODROMO	Texto	Aeropuerto, Aeródromo, Helicóptero, etc.
CODIGO_OACI	Texto	Código OACI internacional
ESTADO	Texto	Estado operativo actual
ADMINISTRADOR	Texto	Entidad administradora
JERARQUIA	Texto	Nivel jerárquico de la instalación
TITULARIDAD	Texto	Titularidad jurídica (pública/privada)
ES_CONCES	Entero	Código de situación de concesión
LATITUD	Decimal	Coordenada geográfica (WGS84)
LONGITUD	Decimal	Coordenada geográfica (WGS84)
FECHA_CORTE	Texto	Fecha de corte del registro (YYYYMMDD)

3.2 Proceso ETL Implementado

3.2.1 Extracción

La extracción se realizó mediante el script `generar_csv_limpio.py`, que lee el archivo XLSX usando la biblioteca `openpyxl` con modo de solo lectura y optimización de memoria. Se implementó una lectura celda

por celda para manejar adecuadamente distintos tipos de datos (fechas, booleanos, números, texto nulo). La primera fila del archivo se utilizó como encabezados de columnas.

3.2.2 Transformación

La fase de transformación aplicó los siguientes pasos de limpieza:

1. **Normalización Unicode (NFKC):** eliminación de caracteres invisibles, espacios de no separación (`\xa0`), caracteres de ancho cero y otras variantes Unicode problemáticas.
2. **Detección de codificación sospechosa:** identificación de caracteres de reemplazo Unicode (`U+FFFD`) y patrones de mojibake que indican errores de codificación en la fuente.
3. **Manejo de valores nulos:** las celdas vacías se convierten a cadenas vacías para mantener consistencia en el esquema de datos.
4. **Conversión de tipos:** las fechas (`datetime`) se formatean como cadenas `YYYY-MM-DD` y los booleanos como `"True"/"False"`.
5. **Creación de columnas derivadas:** generación de tres nuevas variables para el análisis (detalladas en la Consulta 2).

3.2.3 Carga

Los datos procesados se almacenaron en dos archivos CSV con codificación UTF-8-SIG (para compatibilidad con Excel y Power BI):

- `csv_limpio.csv`: datos limpios sin columnas derivadas, utilizados como fuente para el análisis en Python.
- `csv_nuevo.csv`: datos enriquecidos con las tres nuevas columnas (`MACROREGION`, `SITUACION_LEGAL`, `ANIO_CORTE`), utilizados como fuente para Power BI.

3.3 Análisis en Python

El análisis en Python se estructuró en siete consultas ejecutadas secuencialmente en el Jupyter Notebook `PC2-Macro.ipynb`. Cada consulta aplica operaciones de agrupación con Pandas y genera una o más visualizaciones con Matplotlib o Seaborn. Las figuras se exportan en formato PNG (150 dpi) para su inclusión en el informe.

3.4 Dashboards en Power BI

Se desarrollaron cinco páginas de dashboards en Power BI Desktop utilizando `csv_nuevo.csv` como fuente de datos única. La conexión se configuró con delimitador coma y codificación UTF-8. Cada página contiene visualizaciones interactivas con filtros cruzados (cross-filtering) entre los distintos gráficos.

4 Resultados y Discusión

4.1 Consulta 1: Gráficos de Barras Agrupadas

4.1.1 Consulta 1.1 – Infraestructura por Departamento, Tipo y Estado

Se realizó una agrupación por las columnas `DEPARTAMENTO`, `TIPO_AERODROMO` y `ESTADO`, calculando el conteo de `ID_AERODROMO` y la suma de `ID_PROVINCIA`. La visualización muestra los 15 departamentos con mayor número de instalaciones mediante un gráfico de barras agrupadas.




Figure 1: Infraestructura aeroportuaria por departamento, tipo y estado (Top 15 departamentos)

Interpretación: Los departamentos de Loreto y Ucayali encabezan el ranking con el mayor número de instalaciones, predominando los aeródromos en estado operativo. Esta distribución refleja la necesidad crítica del transporte aéreo en la Amazonía, donde la ausencia de infraestructura terrestre hace del avión el único medio práctico de comunicación con comunidades remotas. En contraste, departamentos como Lima y Arequipa presentan menos instalaciones en cantidad pero de mayor jerarquía y capacidad. La proporción de instalaciones en estado cerrado o en mantenimiento es reducida en todos los departamentos, lo que indica un nivel de mantenimiento operativo aceptable del inventario nacional.

4.1.2 Consulta 1.2 – Infraestructura por Administrador, Jerarquía y Titularidad

Se agrupó por ADMINISTRADOR, JERARQUIA y TITULARIDAD, calculando el conteo de registros y la suma de ID.DISTRITO. El gráfico permite identificar la estructura de gestión de la red aeroportuaria.

Gráfico 2: Análisis de Gestión por Administrador, Jerarquía y Titularidad




Figure 2: Infraestructura aeroportuaria por administrador, jerarquía y titularidad

Interpretación: CORPAC S.A. (Corporación Peruana de Aeropuertos y Aviación Comercial) se posiciona como el administrador dominante con presencia en múltiples jerarquías, consolidando el rol del Estado como garante de la conectividad en instalaciones de baja rentabilidad comercial. Los concesionarios privados (Lima Airport Partners, Aeropuertos del Perú) se concentran en instalaciones de alta jerarquía con mayor demanda de tráfico. Los helipuertos privados de la selva corresponden principalmente a empresas del sector extractivo (hidrocarburos y minería) que operan bases logísticas en zonas sin acceso terrestre.

4.2 Consulta 2: Creación de Nuevas Columnas

Se crearon tres columnas derivadas que enriquecen el dataset y habilitan análisis de mayor profundidad:

4.2.1 Columna MACROREGION

Clasifica cada aeródromo en una de tres macrorregiones geográficas según el departamento de ubicación:

- **SELVA:** Loreto, Ucayali, Amazonas, Madre de Dios, San Martín.

- **SIERRA:** Cusco, Puno, Apurímac, Huánuco, Pasco, Junín, Ayacucho, Huancavelica.
- **COSTA:** Todos los departamentos restantes (Lima, Arequipa, La Libertad, Piura, Ica, Tacna, etc.).

Esta clasificación permite análisis regionales que trascienden la división político-administrativa y reflejan las diferencias en condiciones geográficas, de acceso y dinámicas de demanda de transporte aéreo.

4.2.2 Columna SITUACION_LEGAL

Transforma el código numérico de la columna ES_CONCES en una descripción legible del estado jurídico de la instalación:

- **Concesionada** (valor 1): aeródromo bajo contrato de concesión vigente con operador privado.
- **Concesionada (Pendiente de Entrega)** (valor 9): concesión aprobada pero en proceso de transferencia efectiva.
- **Privada (No aplica)** (valor -1): infraestructura de propiedad y operación privada, fuera del régimen de concesiones públicas.
- **Pública (No Concesionada)** (otros valores): administración directa del Estado peruano sin contrato de concesión.

4.2.3 Columna ANIO_CORTE

Extrae el año de corte de la columna FECHA_CORTE (formato YYYYMMDD), generando los valores enteros 2022, 2023 y 2024. Esta columna es la base para todos los análisis de series temporales y evolución del inventario.

4.3 Consulta 3: Matriz de Correlación

Se calculó la matriz de correlación de Pearson entre seis variables numéricas del dataset: ID_DEPARTAMENTO, ID_PROVINCIA, ID_DISTRITO, LATITUD, LONGITUD y ES_CONCES. La visualización se realizó mediante un mapa de calor de Seaborn con paleta `coolwarm`, coeficientes anotados y escala simétrica entre -1 y +1.




Figure 3: Matriz de correlación de Pearson entre variables numéricas del dataset

Interpretación: Se observan correlaciones positivas esperadas entre los identificadores geográficos (ID_DEPARTAMENTO, ID_PROVINCIA, ID_DISTRITO), dado que estos códigos siguen la jerarquía administrativa UBIGEO y están estructuralmente relacionados. Las coordenadas LATITUD y LONGITUD presentan correlaciones moderadas con los identificadores de ubicación, lo que es geográficamente consistente con la distribución espacial de los departamentos peruanos (de norte a sur y de este a oeste). La variable ES_CONCES muestra correlaciones bajas con todas las demás variables, lo que sugiere que la decisión de concesionar una instalación no depende directamente de su posición geográfica sino de factores económicos como el volumen de tráfico pasajero y la rentabilidad proyectada.

4.4 Consulta 4: Gráficos Combinados de Barras Agrupadas

4.4.1 Gráfico 4.1 – Infraestructura por Macroregión, Tipo y Estado

Se visualizó el conteo de instalaciones según la combinación MACROREGION $\times$ TIPO_AERODROMO $\times$ ESTADO, generando un gráfico de barras agrupadas con tres grupos principales (COSTA, SELVA, SIERRA).




Figure 4: Distribución de infraestructura por macroregión, tipo de aeródromo y estado operativo

Interpretación: La SELVA concentra la mayor cantidad de aeródromos (instalaciones menores), confirmando su rol como región con mayor necesidad de infraestructura aérea de escala local. La COSTA, pese a tener menos instalaciones en términos de cantidad, presenta una mayor proporción de aeropuertos de mayor jerarquía. La SIERRA muestra una distribución mixta con aeropuertos en capitales regionales (Cusco, Juliaca, Ayacucho) y aeródromos en provincias. La tasa de instalaciones en estado operativo es elevada en las tres macrorregiones, indicando un mantenimiento activo del inventario.

4.4.2 Gráfico 4.2 – Top 5 Administradores por Jerarquía y Situación Legal

Se identificaron los cinco principales administradores por volumen de instalaciones y se visualizó su distribución según JERARQUIA y SITUACION_LEGAL, usando la paleta viridis para diferenciación cromática.




Figure 5: Top 5 administradores según jerarquía y situación legal de las instalaciones

Interpretación: CORPAC S.A. domina en instalaciones Públicas (No Concesionadas) de múltiples jerarquías, actuando como operador residual del Estado en aeropuertos sin atractivo comercial suficiente para la concesión privada. Los concesionarios privados administran instalaciones de alta jerarquía y elevado tráfico. Los operadores empresariales privados (empresas extractivas) gestionan helicópteros en la selva sin ningún nexo con el régimen de concesiones aeroportuarias públicas.

4.5 Consulta 5: Gráficos de Líneas con Agrupación

4.5.1 Gráfico 5.1 – Evolución por Año, Macroregion y Tipo

Se graficó la evolución temporal (2022–2024) del conteo de registros agrupado por ANIO_CORTE, MACROREGION y TIPO_AERODROMO, con marcadores en cada punto y líneas de color diferenciado por categoría.




Figure 6: Evolución temporal de infraestructura aeroportuaria por macroregion y tipo (2022–2024)

Interpretación: El gráfico de líneas muestra una relativa estabilidad en el número de instalaciones registradas entre 2022 y 2024 para todas las macroregiones y tipos. Esta estabilidad indica que el dataset captura

un inventario consolidado y maduro más que un registro de nuevas construcciones. Las pequeñas variaciones anuales pueden deberse a: actualizaciones del registro oficial (incorporación o retiro de instalaciones), cambios en la categorización de alguna instalación, o correcciones de datos en el sistema fuente. La SELVA mantiene consistentemente la mayor cantidad de registros a lo largo del período.

4.5.2 Gráfico 5.2 – Tendencia por Año, Situación Legal y Jerarquía

Se visualizó la tendencia anual del conteo de instalaciones según ANIO_CORTE, SITUACION_LEGAL y JERARQUIA.




Figure 7: Tendencia temporal de infraestructura por situación legal y jerarquía (2022–2024)

Interpretación: Las instalaciones Públicas (No Concesionadas) presentan la mayor presencia en todos los años del período, seguidas de las instalaciones Privadas. Las variaciones en instalaciones Concesionadas (Pendiente de Entrega) reflejan el dinamismo del proceso concesionario peruano, donde algunos aeropuertos en transición cambian de estado a lo largo de los años. Las instalaciones privadas mantienen una tendencia estable, siendo independientes de las políticas de concesión gubernamental.

4.6 Consulta 6: Gráficos de Tendencia Acumulativa

4.6.1 Gráfico 6.1 – Acumulado por Macroregión

Se graficó el crecimiento acumulativo del conteo de registros por MACROREGION a lo largo de los años de corte, usando la función `cumsum()` de Pandas.




Figure 8: Tendencia acumulativa de registros de infraestructura por macroregión

Interpretación: La curva acumulativa de la SELVA presenta la mayor pendiente, confirmando cuantitativamente que la región amazónica alberga el mayor número de instalaciones en el inventario nacional. La COSTA, pese a concentrar los aeropuertos de mayor jerarquía e importancia económica, presenta un conteo acumulativo menor dada la naturaleza de su infraestructura (pocas instalaciones de gran capacidad frente a muchas instalaciones menores en la selva). La SIERRA mantiene un crecimiento acumulativo intermedio con una pendiente sostenida a lo largo del período.

4.6.2 Gráfico 6.2 – Acumulado por Situación Legal

Se visualizó la acumulación de registros según SITUACION_LEGAL a lo largo del período 2022–2024.




Figure 9: Tendencia acumulativa de registros por situación legal (2022–2024)

Interpretación: Las instalaciones Públicas (No Concesionadas) presentan la mayor acumulación, lo que refleja que el Estado peruano mantiene bajo su administración directa la mayor parte de la red aeroportuaria nacional. Las instalaciones Privadas (No aplica) representan el segundo grupo, asociadas principalmente a helicópteros de empresas extractivas. Las instalaciones bajo concesión vigente son menos numerosas pero de mayor relevancia económica y comercial para el país.

4.6.3 Gráfico 6.3 – Acumulado por Tipo de Aeródromo

Se graficó la acumulación por TIPO_AERODROMO (Aeródromo, Aeropuerto, Helicóptero y otras categorías).




Figure 10: Tendencia acumulativa de registros por tipo de aeródromo (2022–2024)

Interpretación: Los aeródromos (instalaciones menores) dominan el conteo acumulativo, seguidos de los helicópteros, cuya proliferación está directamente vinculada a las actividades de extracción de hidrocarburos y minería en zonas remotas. Los aeropuertos propiamente dichos son los menos numerosos del inventario pero los de mayor impacto en el sistema de transporte nacional, dado que concentran el tráfico regular de pasajeros y carga aérea comercial.

4.7 Consulta 7: Gráficos de Torta con Filtros Condicionales

4.7.1 Gráfico 7.1 – Proporción de Tipos en la Región SELVA

Se filtró el dataset para la macroregión SELVA y se visualizó la distribución porcentual de TIPO_AERODROMO mediante un gráfico de torta con etiquetas de porcentaje.

Gráfico 1: Distribución de Infraestructura en la SELVA




Figure 11: Distribución porcentual de tipos de infraestructura en la macroregión SELVA

Interpretación: En la SELVA, los aeródromos representan la categoría claramente predominante, reflejando la necesidad de infraestructura de escala reducida adaptada a las condiciones del terreno amazónico (pistas en tierra, menor longitud requerida). Los helicópteros ocupan el segundo lugar, correspondiendo en su mayoría a bases de operaciones de empresas petroleras y gasíferas en las cuencas del Oriente. La presencia de aeropuertos internacionales y nacionales es mínima y se concentra en las capitales regionales (Iquitos, Pucallpa, Tarapoto) que actúan como hubs logísticos amazónicos.

4.7.2 Gráfico 7.2 – Distribución de Jerarquía en la Región COSTA

Se filtró el dataset para la macroregión COSTA y se visualizó la distribución porcentual de JERARQUIA en el gráfico de torta.

Gráfico 2: Distribución de Jerarquías en la COSTA




Figure 12: Distribución porcentual de jerarquía de instalaciones en la macroregión COSTA

Interpretación: En la COSTA predominan las instalaciones de mayor jerarquía (internacional y nacional), lo que refleja la concentración de la actividad económica, comercial y poblacional en la franja costera peruana. El Aeropuerto Internacional Jorge Chávez de Lima es la instalación de mayor categoría y la que concentra el mayor volumen de tráfico del país. Los aeropuertos regionales de la costa (Piura, Chiclayo, Trujillo) complementan la red como puntos de conexión doméstica de alta demanda.

4.8 Resultados en Power BI

4.8.1 Páginas C_1_1 y C_1_2 – Gráficos de Columnas Apiladas

C_1_1 presenta un gráfico de columnas apiladas vertical donde el eje X corresponde al departamento y el apilamiento refleja el estado operativo de las instalaciones. Los departamentos de la Amazonía encabezan el ranking, con Loreto y Ucayali como líderes. La visualización interactiva permite filtrar por tipo de aeródromo y año de corte.

C_1_2 utiliza un gráfico de barras apiladas horizontal que facilita la comparación entre administradores con nombres largos. CORPAC S.A. aparece de forma dominante en el segmento Público (No Concesionado), confirmando los hallazgos del análisis en Python.




Figure 13: Dashboards Power BI – Gráficos de columnas y barras apiladas

4.8.2 Páginas C_2_1 y C_2_2 – Gráficos de Líneas

C_2_1 muestra la evolución temporal del conteo de infraestructura por macroregión a lo largo de 2022–2024, confirmando la estabilidad del inventario y la concentración selvática.

C.2.2 presenta la evolución por tipo de aeródromo, evidenciando que los aeródromos mantienen su primacía numérica en todo el período mientras que aeropuertos y helicópteros se mantienen relativamente constantes.




Figure 14: Dashboards Power BI – Gráficos de líneas temporales 2022–2024

4.8.3 Página C.3 – Diagramas de Dispersión

Se presentan cuatro variantes de diagramas de dispersión (Latitud vs. Longitud) con diferenciación cromática por: tipo de aeródromo, macroregión, estado operativo y situación legal. Esta visualización permite identificar la distribución espacial real de las instalaciones y detectar anomalías.

Hallazgo relevante: Los diagramas de dispersión revelaron inconsistencias en la clasificación geográfica del dataset: algunas instalaciones categorizadas en la macroregión COSTA presentan coordenadas de longitud correspondientes a zonas amazónicas (longitudes superiores a -76°), lo que sugiere posibles errores en la asignación departamental del registro oficial o en los límites de la clasificación de macroregiones empleada en el estudio.




Figure 15: Dashboard Power BI – Distribución espacial mediante diagramas de dispersión (Latitud vs. Longitud)

4.8.4 Página C.4 – Mapa de Burbujas

Se implementó un mapa geográfico interactivo usando las columnas LATITUD y LONGITUD del dataset enriquecido. El tamaño de las burbujas es proporcional al conteo de instalaciones en cada punto geográfico, con diferenciación de color por macroregión. El mapa confirma visualmente la concentración de infraestructura en la Amazonía y la distribución de aeropuertos de mayor jerarquía en la Costa.




Figure 16: Dashboard Power BI – Mapa de distribución geográfica de aerodromos a nivel nacional

4.8.5 Página C.5 – Gráfico de Torta

La página final presenta la participación porcentual de cada macroregión en el total de infraestructura aeroportuaria nacional, confirmando que la SELVA concentra la mayor proporción del inventario, seguida de la SIERRA y la COSTA.




Figure 17: Dashboard Power BI – Participación porcentual de infraestructura por macroregión

4.9 Resumen de Hallazgos

El análisis integrado permite consolidar los siguientes hallazgos principales:

1. **Concentración amazónica:** La región Selva concentra el mayor número de instalaciones (aeródromos y helicópteros), siendo el transporte aéreo la principal vía de conectividad para comunidades rurales y operaciones extractivas en la Amazonía peruana.

2. **Dominancia de CORPAC S.A.:** La Corporación Peruana de Aeropuertos y Aviación Comercial administra la mayoría de instalaciones públicas no concesionadas, actuando como garante estatal de la conectividad en zonas sin atractivo para la inversión privada.
3. **Estabilidad del inventario 2022–2024:** El número de instalaciones registradas se mantiene relativamente estable en el trienio, con variaciones menores atribuibles a actualizaciones del registro oficial y cambios de estado de instalaciones individuales.
4. **Inconsistencias geográficas:** Los diagramas de dispersión de Power BI detectaron instalaciones cuyas coordenadas no coinciden con la macroregión asignada, evidenciando la necesidad de procesos de validación más rigurosos en la publicación de datos gubernamentales abiertos.
5. **Baja correlación entre ubicación y concesión:** El análisis de correlación indica que la decisión de concesionar una instalación no depende primariamente de su posición geográfica, sino de factores económicos y de demanda de tráfico.

5 Conclusiones

El presente trabajo demostró la efectividad de las herramientas de macrodatos para el análisis de infraestructura de transporte a escala nacional. A través del proceso ETL y el análisis exploratorio multidimensional, se obtuvo una comprensión profunda de la distribución, administración y evolución temporal de la infraestructura aeroportuaria peruana para el período 2022–2024.

Las principales conclusiones son:

- El proceso ETL implementado en Python con normalización Unicode y detección de codificación sospechosa permitió transformar datos crudos en formato XLSX a un conjunto de datos limpio y confiable. La creación de las columnas derivadas MACROREGION, SITUACION_LEGAL y ANIO_CORTE añadió un valor analítico significativo que no estaba explícito en el dataset original.
- El análisis en Python con Pandas, Matplotlib y Seaborn permitió identificar patrones de concentración geográfica y administrativa que no son evidentes en los datos crudos. Las 7 consultas generaron 12 visualizaciones complementarias que ofrecen una perspectiva multidimensional del sistema aeroportuario peruano.
- Los dashboards de Power BI enriquecieron el análisis estático de Python con visualizaciones interactivas y georreferenciadas. En particular, el mapa de burbujas y los diagramas de dispersión aportaron una dimensión espacial que potenció la interpretación de los resultados.
- La detección de inconsistencias en la clasificación geográfica de algunas instalaciones es un resultado relevante que evidencia la importancia de la validación de datos en proyectos de datos abiertos. Se recomienda que el ente publicador revise los registros cuyas coordenadas no corresponden a la división geográfica declarada.
- La estabilidad del inventario en 2022–2024 sugiere que la política aeroportuaria peruana en este período se orientó más a la consolidación y mantenimiento de la infraestructura existente que a la expansión de nuevas instalaciones. Las políticas futuras deberían enfocarse en mejorar la capacidad y calidad de los aeródromos existentes, especialmente en la región Selva.

6 Anexo: Código Python

El código completo del análisis se encuentra en el archivo `PC2-Macro.ipynb` y su versión exportada `pc2_macro.py` en el repositorio del proyecto. A continuación se presentan los extractos más relevantes:

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5
6 # Carga del CSV limpio generado por el proceso ETL
7 df = pd.read_csv("CSV_final/csv_limpio.csv")
8 print(f"Shape: {df.shape}")

```

```

9 print(df.columns.tolist())
10 print(df.dtypes)
11 print(df.head())

```

Listing 1: Carga del dataset y exploración inicial

```

1 # Agrupacion por DEPARTAMENTO, TIPO_AERODROMO y ESTADO
2 grupo1 = df.groupby(['DEPARTAMENTO', 'TIPO_AERODROMO', 'ESTADO']).agg(
3     conteo=('ID_AERODROMO', 'count'),
4     suma_prov=('ID_PROVINCIA', 'sum')
5 ).reset_index()
6
7 # Seleccionar los 15 departamentos con mas instalaciones
8 top_dep = df['DEPARTAMENTO'].value_counts().head(15).index
9 grupo1_top = grupo1[grupo1['DEPARTAMENTO'].isin(top_dep)]
10
11 # Visualizacion
12 fig, ax = plt.subplots(figsize=(14, 6))
13 # ... (código de pivote y visualizacion de barras agrupadas)
14 plt.tight_layout()
15 plt.savefig('fig/consulta1_1.png', dpi=150, bbox_inches='tight')
16 plt.show()

```

Listing 2: Consulta 1.1 – Agrupación por departamento, tipo y estado

```

1 # --- MACROREGION ---
2 selva = ['LORETO', 'UCAYALI', 'AMAZONAS', 'MADRE DE DIOS', 'SAN MARTIN']
3 sierra = ['CUSCO', 'PUNO', 'APURIMAC', 'HUANUCO', 'PASCO',
4           'JUNIN', 'AYACUCHO', 'HUANCAVELICA']
5
6 def asignar_macroregion(dep):
7     d = dep.upper().strip()
8     if d in selva: return 'SELVA'
9     if d in sierra: return 'SIERRA'
10    return 'COSTA'
11
12 df['MACROREGION'] = df['DEPARTAMENTO'].apply(asignar_macroregion)
13
14 # --- SITUACION_LEGAL ---
15 def clasificar_situacion(val):
16     if val == 1: return 'Concesionada'
17     if val == 9: return 'Concesionada (Pendiente de Entrega)'
18     if val == -1: return 'Privada (No aplica)'
19     return 'Publica (No Concesionada)'
20
21 df['SITUACION_LEGAL'] = df['ES_CONCES'].apply(clasificar_situacion)
22
23 # --- ANIO_CORTE ---
24 df['ANIO_CORTE'] = df['FECHA_CORTE'].astype(str).str[:4].astype(int)
25
26 # Exportar CSV enriquecido para Power BI
27 df.to_csv("CSV_final/csv_nuevo.csv", index=False, encoding='utf-8-sig')

```

Listing 3: Consulta 2 – Creación de columnas derivadas

```

1 cols_corr = ['ID_DEPARTAMENTO', 'ID_PROVINCIA', 'ID_DISTRITO',
2             'LATITUD', 'LONGITUD', 'ES_CONCES']
3
4 corr_matrix = df[cols_corr].corr()
5
6 fig, ax = plt.subplots(figsize=(8, 6))
7 sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='coolwarm',
8             ax=ax, vmin=-1, vmax=1, center=0,
9             linewidths=0.5, square=True)
10 ax.set_title('Matriz de Correlacion de Pearson', fontsize=13, pad=12)
11 plt.tight_layout()
12 plt.savefig('fig/consulta3.png', dpi=150, bbox_inches='tight')
13 plt.show()

```

Listing 4: Consulta 3 – Matriz de correlación con Seaborn

```

1 # Agrupacion anual por macrorregion
2 evo = df.groupby(['ANIO_CORTE', 'MACROREGION']).size().reset_index(name='conteo')
3
4 # Calculo de cumsum por macrorregion
5 evo_pivot = evo.pivot(index='ANIO_CORTE', columns='MACROREGION',
6                       values='conteo').fillna(0)
7 evo_acum = evo_pivot.cumsum()
8
9 fig, ax = plt.subplots(figsize=(10, 5))
10 for col in evo_acum.columns:
11     ax.plot(evo_acum.index, evo_acum[col], marker='o', label=col, linewidth=2)
12
13 ax.set_xlabel('Año de Corte')
14 ax.set_ylabel('Conteo Acumulativo')
15 ax.set_title('Tendencia Acumulativa por Macrorregion')
16 ax.legend()
17 plt.tight_layout()
18 plt.savefig('fig/consulta6_1.png', dpi=150, bbox_inches='tight')
19 plt.show()

```

Listing 5: Consulta 6 – Tendencia acumulativa por macroregión

7 Anexo: Documentación del Dataset

Ficha Técnica de la Fuente de Datos

- **Nombre del dataset:** Infraestructura Aeroportuaria – Aeródromos 2022 a 2024
- **Entidad publicadora:** Ministerio de Transportes y Comunicaciones del Perú (MTC), bajo la Secretaría de Gobierno Digital – Presidencia del Consejo de Ministros
- **Plataforma:** Plataforma Nacional de Datos Abiertos (PNDA)
- **URL del dataset:** <https://www.datosabiertos.gob.pe/dataset/infraestructura-aeroportuaria-aerodromos>
- **Categoría:** Transporte
- **Fecha de publicación:** 16 de junio de 2025
- **Última actualización:** 16 de junio de 2025
- **Recursos disponibles:** 3 archivos – archivo principal XLSX, metadatos y diccionario de datos
- **Nombre del archivo principal:** Infraestructura_aeroportuaria_aerodromos_2022-2024.xlsx
- **Tamaño del archivo:** 77.86 KB
- **Formato original:** Microsoft Excel (XLSX – application/vnd.openxmlformats-officedocument.spreadsheetml.sheet)
- **Período cubierto:** 2022, 2023 y 2024 (cortes al 31 de diciembre de cada año)
- **Cobertura geográfica:** Nacional – 25 departamentos del Perú
- **Número de columnas originales:** 21
- **Sistema de coordenadas:** WGS84 (LATITUD y LONGITUD en grados decimales)
- **Contacto PNDA:** mesadeayuda@gobiernodigital.gob.pe – Calle Schell 310, Miraflores, Lima

Diccionario Completo de Datos

Table 2: Diccionario de datos del dataset de infraestructura aeroportuaria

Campo	Tipo	Descripción detallada
ID_AERODROMO	Entero	Identificador único secuencial del aeródromo en el registro nacional
ID_DEPARTAMENTO	Entero	Código UBIGEO nivel 1 (departamento)
ID_PROVINCIA	Entero	Código UBIGEO nivel 2 (provincia)
ID_DISTRITO	Entero	Código UBIGEO nivel 3 (distrito)
DEPARTAMENTO	Texto	Nombre oficial del departamento de ubicación
PROVINCIA	Texto	Nombre oficial de la provincia de ubicación
DISTRITO	Texto	Nombre oficial del distrito de ubicación
NOMBRE	Texto	Nombre oficial del aeródromo según el registro MTC
LABEL	Texto	Etiqueta de identificación alternativa o abreviada
TIPO_AERODROMO	Texto	Clasificación: Aeropuerto, Aeródromo, Helicóptero, u otros
CODIGO_AERODROMO	Texto	Código interno del MTC para la instalación
CODIGO_OACI	Texto	Código de 4 letras de la Organización de Aviación Civil Internacional
ESCALA	Texto	Escala o capacidad operativa de la instalación
ESTADO	Texto	Estado actual: Operativo, Cerrado, En construcción, Inactivo, etc.
ADMINISTRADOR	Texto	Entidad responsable de la administración (CORPAC, concesionarios, empresas privadas)
JERARQUIA	Texto	Nivel jerárquico: Internacional, Nacional, Regional, Local
TITULARIDAD	Texto	Titularidad jurídica: Pública, Privada, Mixta
LATITUD	Decimal	Coordenada geográfica de latitud en grados decimales (WGS84)
LONGITUD	Decimal	Coordenada geográfica de longitud en grados decimales (WGS84)
ES_CONCES	Entero	Estado de concesión: 1=concesionada, 9=pendiente, -1=privada, otros=pública
FECHA_CORTE	Texto	Fecha de corte del registro en formato YYYYMMDD
<i>Columnas derivadas (generadas en el proceso ETL):</i>		
MACROREGION	Texto	Región geográfica: SELVA, SIERRA o COSTA (generada según departamento)
SITUACION_LEGAL	Texto	Descripción legible del estado de concesión (generada desde ES_CONCES)
ANIO_CORTE	Entero	Año de corte extraído de FECHA_CORTE (2022, 2023 o 2024)

Estructura de Archivos del Proyecto

- CSV_base/xlsx_file.xlsx — Archivo fuente original descargado de la PNDA
- generar_csv_limpio.py — Script de extracción, limpieza y normalización
- CSV_final/csv_limpio.csv — Dataset limpio para análisis en Python
- CSV_final/csv_nuevo.csv — Dataset enriquecido con columnas derivadas para Power BI
- Resultados/Python/PC2-Macro.ipynb — Jupyter Notebook con las 7 consultas de análisis
- Resultados/Python/pc2_macro.py — Script Python exportado del notebook
- Resultados/PowerBi/PC2-Macro.pbix — Archivo Power BI Desktop con los 5 dashboards
- Resultados/PowerBi/README.md — Documentación de las visualizaciones de Power BI
- Diccionario_Datos_aerodromos_2022-2024.xlsx — Diccionario de datos oficial del MTC

References

- [1] Min Chen, Shiwen Mao, and Yunhao Liu. Big data: A survey. *Mobile Networks and Applications*, 19:171–209, 2014.
- [2] CORPAC S.A. Corporación peruana de aeropuertos y aviación comercial. <https://www.corpac.gob.pe>, 2023.
- [3] Alberto Ferrari and Marco Russo. *Introducing Microsoft Power BI*. Microsoft Press, 2016.
- [4] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, et al. Array programming with NumPy. *Nature*, 585:357–362, 2020.
- [5] John D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [6] Ralph Kimball and Joe Caserta. *The Data Warehouse ETL Toolkit*. Wiley Publishing, 2004.
- [7] James Manyika, Michael Chui, Brad Brown, Jacques Bughin, Richard Dobbs, Charles Roxburgh, and Angela H. Byers. Big data: The next frontier for innovation, competition, and productivity. Technical report, McKinsey Global Institute, 2011.
- [8] Wes McKinney. *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 3rd edition, 2022.
- [9] Ministerio de Transportes y Comunicaciones del Perú. Infraestructura aeroportuaria – aeródromos 2022 a 2024. Plataforma Nacional de Datos Abiertos (PNDA), Secretaría de Gobierno Digital – Presidencia del Consejo de Ministros, 2025. Publicado el 16 de junio de 2025. Archivo: `Infraestructura_aeroportuaria_aerodromos_2022-2024.xlsx` (77.86 KB). Disponible en: <https://www.datosabiertos.gob.pe/dataset/infraestructura-aeroportuaria-aerodromos-2022-2024-ministerio-de-transportes-y-0>.
- [10] Presidencia del Consejo de Ministros del Perú. Plataforma nacional de datos abiertos. <https://www.datosabiertos.gob.pe>, 2024.
- [11] Erhard Rahm and Hong Hai Do. Data cleaning: Problems and current approaches. *IEEE Data Engineering Bulletin*, 23(4):3–13, 2000.
- [12] Michael L. Waskom. Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021.