

Escuela de Ciencia de la Computación

Laboratorio 01

CC531 A Análisis en Macrodatos 2026 - 1

Parte 1: [5pts]

Resolver un ejercicio en computadora dejado por el docente, duración 30 min (si el alumno llega después de 10 minutos iniciado ya no se considera esa parte)

Parte 2: [15 pts]

Configurar una instalación de Hadoop con las versiones vistas en clase, Investigar, implementar y exponer un informe y presentación teniendo en cuenta lo siguiente:

- Implementar o usar su VM de un nodo para correr los programas elaborados
- Buscar una base de datos de la Plataforma Nacional de Datos Abiertos (PNDA) relacionado a **DESARROLLO SOCIAL**, coordinar para que no se repitan Dataset entre los grupos.
- Tanto en el informe como en la presentación: o Referenciar la base de datos usada.
 1. Referencias investigaciones anteriores realizadas a la base datos.
 2. Indicar la fuente de dataset y la fecha de publicación, se tomará en cuenta las bases de datos más recientes.
 3. Referenciar artículos que usaron su dataset si lo hubiera hecho.
- Resolver 7 tipos de consultas propuestas sobre MapReduce, para cada consulta hacer su enunciado de la pregunta a la cual responde:
 1. Hacer 4 consultas Map reduce que usen 2 campos (Columnas) o más cada una.
 2. Encontrar el promedio, la media y la desviación de un campo (Columna) a selección.
 3. Hacer búsqueda de un subtexto general que pueda buscar en varios campos de textos y me dé como resultado(s) uno o varios registros completos.
 4. Hacer una búsqueda por intervalo de fechas y dar como reporte uno o más registros completos.
 5. El mayor y el menor valor de un campo o un conjunto de campos (Columnas) agrupados.
 6. Hacer 2 consultas con campos decimales que implique al menos 2 MapReduce. Cada consulta por separado debe tener los 2 Mapreduce enlazados.
 7. Hacer 1 consulta con campos decimales o texto que implique el uso de un modelo de clasificación (investigar)
 8. Hacer 1 consulta con campos decimales que implique el uso de un modelo de Regresión. (investigar)
- Observar el monitor de recursos y colocar en su informe los datos más representativos.
- En el informe y presentación para mantener la organización por cada consulta se debe mencionar:
 1. Especificar el tipo de pregunta o grupo de pregunta.
 2. Mencionar la consulta en el Dataset a la cual responde. Ejem: "Cual es el promedio de marcas usadas..."

3. Explicar la solución y resultados.

- Agregar al informe y presentación los inputs y outputs que pudiera tener sus consultas.
- **Durante la exposición se debe mostrar la ejecución del hadoop en una pregunta seleccionada por el docente.**

Donde se tenga en cuenta de:

- Tomar como base las prácticas de clase y las versiones usadas en ella de ser posible.
- Explorar y analizar la información.
- Interpretación de los resultados.
- Para la segunda parte serán en grupos de **hasta máximo 3 personas** como máximo y personas del grupo deben estar presentes al momento de la exposición sino no se considerará su evaluación por más que coloquen como miembro en su presentación.
- No está permitido implementar hadoop con otra tecnología como contenedores, de lo contrario se restarán los respectivos puntos por cada pregunta.

Comprimir todos los archivos en un archivo con las siguientes pautas:

- Utilizar las plantillas adjuntas en la tarea.
- Adjuntar los códigos con extensión java y también jar.
- Adjuntar el Informe con la plantilla.
- Adjuntar la presentación de su proyecto
- Entregar todo en un zip a través del aula virtual UNI hasta la fecha límite. (cada integrante del grupo debe subirlo por separado)

Comprimir todos los archivos en un archivo:

- Utilizar la Plantilla en un archivo PDF:
 - Adjuntar los códigos con extensión java y también los .jar.
 - Adjuntar el Informe en PDF.
 - Adjuntar la presentación de su proyecto.
 - Entregar todo en un zip a través del aula virtual UNI hasta la fecha límite. Cada integrante del grupo debe subir su trabajo para que quede registro de su participación.