

Escuela de Ciencia de la Computación

Laboratorio 03

CC531 A Análisis en Macrodatos 2026-1

Configurar el Spark, Spark SQL, Investigar, desarrollar un informe y exponer una presentación sobre un conjunto de datos seleccionado para análisis. Realizar las siguientes acciones:

1. Buscar una base de datos de la Plataforma Nacional de Datos Abiertos (PNDA) relacionado **MEDIO AMBIENTE Y RECURSOS NATURALES**, que además que no haya sido utilizado en evaluaciones anteriores ni por otro grupo. **Esta prohibido usar el mismo dataset incluso si fuera otro periodo de tiempo o sub conjuntos diferentes del mismo.**
2. Describir detalles de la base de datos, el rubro de la organización de la base de datos, describir la teoría que implica los datos (por ejemplo, si es de biología, acciones, objetos, etc.), que características tiene la base de datos, campos detalles, reglas de los datos, que información usted cree, que se podría obtener de la base de datos.
3. Utilizando el lenguaje Scala – spark y usando mapreduce:
 - a. Agrupar un campo por tipos y de otro campo numérico encontrar los mayores y menores usando mapreduce.
 - b. Encontrar el promedio, la media, la desviación, el mayor y el menor de un campo a selección usando mapreduce.
 - c. Hacer 3 consultas con decimales que implique al menos 3 mapreduce. En cada consulta tripe map reduce.
4. Almacenar dicho dataset en una base de datos Postgres donde el estudiante deberá definir la arquitectura de las tablas y los campos necesarios para ello. Implementa una sección en el informe denominado “Proceso ETL para la base de datos” donde se detalle los pasos ETL seguidos para extraer la información de dataset, definir la arquitectura de la DB con diagramas Entidad-Relación y finalmente el llenado de los datos. Incluir en el informe Capturas de Pantalla de su DB funcionando.
5. Utilizando Spark SQL:

Utilizando el API de Scala – Spark SQL hacer consultas:

 - a. 3 consultas mostrar columnas específicas de las tablas seleccionadas por el comando filter que involucren 2 o más columnas de filtro.
 - b. 3 consultas utilizando el comando groupBy y count
 - c. 1 consulta que incluya el promedio de una columna y 1 de ordenamiento decreciente
 - d. 3 consultas que incluya el comando Join en sus diversos tipos.
 - e. 3 consultas utilizando las funciones de org.apache.spark.sql.functions._

Utilizando Vistas temporales y spark SQL hacer consultas de:

 - f. 3 selección utilizando join en sus diversos tipos (diferente a 5d).
 - g. 3 GroupBy usando count (diferentes que 5b)
 - h. 3 OrderBy combinado con otros operadores de filtro.
6. Según las preguntas antes solicitadas realizar:
 - Las consultas de scala, scala-spark-SQL y vistas temporales las cuales deben ser diferentes o estar referidas a diferentes objetivos.
 - Usar las mismas versiones de spark y postgresql usados en clases

- Elaborar un informe y una presentación.
7. En el informe y presentación para mantener la organización por cada consulta se debe mencionar (muy importante en la puntuación de su informe: -
Especificar el tipo de pregunta o grupo de pregunta.
Mencionar la consulta en el Dataset a la cual responde. Ejem: “Cual es el promedio de marcas usadas...”
Explicar la solución e interpretación de los resultados de cada consulta y como dan acceso a la respuesta, indicando las columnas, filas o características que se usan para ello **y las partes importantes del código.**
8. Entregables:
- Códigos spark con la extensión. scala y sus salidas (Obligatorio)
 - Sentencias o Códigos de creación y llenado de la base de datos Postgres (Obligatorio)
 - Archivo de exportación de la base de datos postgres (.sql)(Obligatorio)
 - Informe y presentación (Obligatorio)
 - El dataset utilizado.
 - Cada miembro del grupo deberá entrega lo antes mencionado en un zip por el aula virtual.
9. Observaciones importantes:
- Esta prohibido que dos o más grupos utilicen el mismo dataset incluso con rango de fechas o sub partes diferentes, de presentarse el caso no se evaluará a ningún de los grupos involucrados.
 - El tiempo limite de exposición es de 10 minutos, de pasarse ese tiempo o hacer bulla o distracción en el aula se aplicarán descuento de puntos.
 - Todos los entregables deben presentarse como máximo hasta la fecha establecida en el aula virtual. No se darán plazo adicional de entrega.
 - De no presentarse todo entregable calificado como obligatorio, dado que son componentes básicos para demostrar el trabajo realizado, no se evaluará dicho trabajo o se colocará un puntaje en base a lo que pueda ser verificado.

Tabla de calificación

Item	Objetivo	Puntuación (Hasta...)
Informe	Informe bien explicado con todas las pautas del enunciado y las partes solicitadas	2
Generación de la DB con ETL	DB generada y llenada, con descripción detallada en el informe y script o comandos de creación y DB exportada	2
presentación	Presentación con todos los puntos del informe	1
Exposición	Exposición clara sin leer y en el rango de tiempo y consultas.	2
pregunta 3 A	Archivo de Código y salida así como explicación según formato del enunciado	1
Pregunta 3 B	Archivo de Código y salida así como explicación según formato del enunciado	1
Pregunta 3C	Archivo de Código y salida así como explicación según formato del enunciado	2
Pregunta 5 (0,5 x pregunta)	Archivo de Código y salida así como explicación según formato del enunciado	4