

Escuela de Ciencia de la Computación

Practica 04

CC531 A Análisis en Macrodatos 2026-1

Investigar, Exponer y Desarrollar un informe de una base de datos externa con Spark para su Análisis con Scala en Spark ML relacionado al área de **Ciencia y tecnología o energía** que tengan información adecuada para aplicar modelos de clasificación y regresión. Realizar las siguientes acciones:

1. Buscar una base de datos de la Plataforma Nacional de Datos Abiertos (PNDA) relacionado a **Ciencia y tecnología o energía**, que además que no haya sido utilizado en evaluaciones anteriores ni por otro grupo. Está prohibido usar el mismo dataset incluso si fuera otro periodo de tiempo o subconjuntos diferentes del mismo.
2. Describir detalles de la base de datos, el rubro de la organización de la base de datos, describir la teoría que implica los datos (por ejemplo, si es de biología, acciones, objetos, etc.), que características tiene la base de datos, campos detalles, reglas de los datos, que información usted cree, que se podría obtener de la base de datos.
3. Utilizando Spark ML de implementar los siguientes Modelos de Machine Learning:
 - Elaborar en spark usando ML implementar los siguientes modelos de clasificación:
 - Árboles de Decisión
 - Random Forest
 - Regresión Logística Multiclase.
 - Naive Bayes
 - Elaborar en spark usando ML los siguientes modelos de regresión
 - Regresión lineal
 - Multilayer Perceptron
 - SVM para regresión. (SVR)
 - XGBOST
 - Usar pipeline para procesamiento de datos como limpieza, eliminación de nulos y one-hot encoding. El proceso de limpieza debe estar detallado en el informe y presentación.
 - Generar una tabla donde comparen las siguientes métricas: Accuracy, Precisión, Recall, F1-score para el caso de modelos de clasificación.
 - Generar una tabla donde comparen las siguientes métricas: RMSE, MSE, MAE, R^2 para el caso de modelos de regresión.
 - Utilizar Grid-Search para obtener los mejores valores de métricas.
 - Mostrar Graficas que representen las pérdidas de sus modelos y adjuntarlos en el informe.

- Ejecutar algunos ejemplos de prueba de los modelos elaborados luego del entrenamiento.
 - Usar la versión de spark y librerías usadas en clase.
 - Interpretación de los resultados los cuales deben ir plasmados en el informe.
4. Elaborar un informe y una presentación para mantener la organización por cada consulta se debe mencionar (muy importante en la puntuación de su informe: - Especificar el tipo de pregunta o grupo de pregunta.
Mencionar la consulta en el Dataset a la cual responde. Ejem: "Cual es el promedio de marcas usadas..."
Explicar la solución e interpretación de los resultados de cada consulta y como dan acceso a la respuesta, indicando las columnas, filas o características que se usan para ello y las partes importantes del código.
5. Entregables:
- Códigos spark con la extensión. scala y sus salidas (Obligatorio)
 - Informe y presentación (Obligatorio).
 - Gráficos generados de las pérdidas
 - El dataset utilizado.
 - Cada miembro del grupo deberá entrega lo antes mencionado en un zip por el aula virtual.
6. Observaciones importantes:
- Los grupos serán de 3 personas a lo sumo.
 - Esta prohibido que dos o más grupos utilicen el mismo dataset incluso con rango de fechas o sub partes diferentes, de presentarse el caso no se evaluará a ningún de los grupos involucrados.
 - El tiempo limite de exposición es de 10 minutos, de pasarse ese tiempo o hacer bulla o distracción en el aula se aplicarán descuento de puntos.
 - Todos los entregables deben presentarse como máximo hasta la fecha establecida en el aula virtual. No se darán plazo adicional de entrega.
 - De no presentarse todo entregable calificado como obligatorio, dado que son componentes básicos para demostrar el trabajo realizado, no se evaluará dicho trabajo o se colocará un puntaje en base a lo que pueda ser verificado.

Item	Objetivo	Puntuación hasta...
Informe	Informe bien explicado con todas las pautas del enunciado y las partes solicitadas	2
Presentación	Presentación con todos los puntos del informe	1
Preguntas de ML clasificación (0,5 x pregunta)	Archivo de Código y salida, así como explicación según formato del enunciado	2
Preguntas de ML Regresión. (0,5 x pregunta)	Archivo de Código y salida, así como explicación según formato del enunciado	2
Uso de pipeline	Uso de pipeline para preprocesamiento y/o	1

	implementación del modelo de ML.	
Uso de grid Search en ambos casos	Evidencias en el informe o imágenes de que hizo GS.	1
Exposición	Exposición clara sin leer y en el rango de tiempo y consultas.	2
Tabla de comparación de métricas de Clasificación	Tabla elaborada y explicada sobre las métricas calculadas	2
Tabla de comparación de métricas de regresión	Tabla elaborada y explicada sobre las métricas calculadas	2